

1ª Atividade Prática de Estatística Indutiva

Curso de Ciência de Dados - 3º ciclo

Profª. Márcia Roberta S. Pires Silva

Integrantes

Diego Pacheco Hissnauer

Kauan Nunes Vieira Santos

Rafael Manfe Bisaio

Victor Gabriel Leme da Silva

Apresentação/Contexto

O arquivo `clientes_plataforma_streaming.csv` reúne informações de $N = 100\,000$ clientes de uma plataforma de streaming. A variável estudada é `Gasto_reais`, o gasto de cada cliente, em reais.

Neste relatório, os cálculos seguem o método visto em aula: valores críticos lidos nas tabelas impressas (Tabela III, normal padrão; Tabela V, t de Student), variância amostral com divisor $n - 1$, graus de liberdade $\nu = n - 1$ e conclusões escritas na linguagem do problema. O software R foi usado para sortear as amostras e para conferir as contas; o código está no repositório do trabalho (`streaming-spend-inference`, no GitHub) e todos os sorteios usam a semente 42, o que permite repetir exatamente os mesmos resultados.

1 Parte 1: Amostra-piloto

Como a amostra foi sorteada

A população é formada pelos $N = 100\,000$ clientes, que já vêm numerados de 1 a N pela coluna `Cliente_ID`. Isso nos dá o quadro amostral, a lista de todos os elementos da população, necessária para a amostragem aleatória simples (AAS).

Foram sorteados $n = 25$ números distintos entre 1 e 100 000, ou seja, uma AAS **sem reposição**, porque cada cliente deve aparecer no máximo uma vez. Cada cliente tem a

mesma probabilidade de entrar na amostra:

$$P = \frac{n}{N} = \frac{25}{100\,000} = 0,00025 = 0,025\%.$$

No R, o sorteio foi feito com `set.seed(42)` seguido de `sample(1:100000, 25)`.

(a) Dados da amostra-piloto

Seja X o gasto, em reais, de um cliente da plataforma, e $X_1, \dots, X_{25}$ os gastos dos 25 clientes sorteados.

i	Cliente_ID	Gasto x_i (R\$)
1	61413	307,21
2	54425	375,28
3	99556	1 405,57
4	74362	376,63
5	46208	1 467,55
6	47128	1 262,81
7	16740	707,08
8	61605	329,86
9	73236	905,18
10	9091	589,42
11	62041	1 498,96
12	33700	521,75
13	59359	814,28
14	54789	442,49
15	54586	689,20
16	13610	455,13
17	28559	1 187,84
18	88261	1 185,36
19	11224	995,16
20	33713	709,38
21	64410	175,72
22	77954	207,86
23	81301	583,06
24	74743	568,56
25	96954	1 387,04

(b) Média e variância

A média amostral é

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{19\,148,38}{25} = 765,9352.$$

A variância amostral usa o divisor $n - 1$ (aula 03), porque $\bar{x}$ já foi calculada com os mesmos dados e, por isso, apenas $n - 1$ desvios podem variar livremente:

$$S^2 = \frac{1}{n - 1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Para fazer a soma, calculamos primeiro o desvio de cada valor em relação à média e o quadrado desse desvio:

i	x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
1	307,21	-458,7252	210 428,8091
2	375,28	-390,6552	152 611,4853
3	1 405,57	639,6348	409 132,6774
4	376,63	-389,3052	151 558,5387
5	1 467,55	701,6148	492 263,3276
6	1 262,81	496,8748	246 884,5669
7	707,08	-58,8552	3 463,9346
8	329,86	-436,0752	190 161,5801
9	905,18	139,2448	19 389,1143
10	589,42	-176,5152	31 157,6158
11	1 498,96	733,0248	537 325,3574
12	521,75	-244,1852	59 626,4119
13	814,28	48,3448	2 337,2197
14	442,49	-323,4452	104 616,7974
15	689,20	-76,7352	5 888,2909
16	455,13	-310,8052	96 599,8723
17	1 187,84	421,9048	178 003,6603
18	1 185,36	419,4248	175 917,1629
19	995,16	229,2248	52 544,0089
20	709,38	-56,5552	3 198,4906
21	175,72	-590,2152	348 353,9823
22	207,86	-558,0752	311 447,9289
23	583,06	-182,8752	33 443,3388
24	568,56	-197,3752	38 956,9696
25	1 387,04	621,1048	385 771,1726
Soma dos quadrados dos desvios			4 241 082,31

Os desvios somam zero (a menos de arredondamento), como deve ocorrer em torno da

média. Substituindo:

$$S^2 = \frac{4\,241\,082,31}{25 - 1} = \frac{4\,241\,082,31}{24} = 176\,711,76 \text{ (R\$}^2\text{)}.$$

O desvio padrão amostral é $S = \sqrt{S^2} = \sqrt{176\,711,76} = 420,37$ reais.

Resultado da Parte 1: $\bar{x} = \text{R\$ } 765,9352$ e $S^2 = 176\,711,76 \text{ R\2 .

2 Parte 2: Intervalo de confiança

Escolha da distribuição

Seja X o gasto de um cliente e $\bar{X}$ amostral o gasto dos 25 clientes da piloto. O enunciado manda considerar a variância populacional σ^2 **desconhecida**. Nesse caso, o desvio padrão da população é substituído por S e a variável padronizada não segue a normal, e sim a distribuição **t de Student com $\nu = n - 1$ graus de liberdade**. Admite-se, como na disciplina, que a média amostral tem comportamento aproximadamente normal (Teorema do Limite Central).

Dados

$n = 25$, $\nu = 24$, $\bar{x} = 765,9352$, $S = 420,3710$, confiança $1 - \alpha = 95\%$, logo $\alpha = 0,05$.

Fórmula

$$IC(\mu; 95\%) = \left[\bar{x} - t_{\alpha/2} \cdot \frac{S}{\sqrt{n}} ; \bar{x} + t_{\alpha/2} \cdot \frac{S}{\sqrt{n}} \right].$$

Cálculos

1. Erro padrão estimado:

$$\frac{S}{\sqrt{n}} = \frac{420,3710}{\sqrt{25}} = \frac{420,3710}{5} = 84,0742.$$

2. Valor crítico. A Tabela V é bicaudal: a coluna indica a soma das áreas das duas caudas. Para confiança de 95%, usa-se a coluna $p = \alpha = 5\%$, na linha $\nu = 24$:

$$t_{\alpha/2} = 2,064.$$

3. Margem de erro:

$$e = 2,064 \cdot 84,0742 = 173,5291.$$


4. Limites do intervalo:

$$\bar{x} - e = 765,9352 - 173,5291 = 592,4061, \quad \bar{x} + e = 765,9352 + 173,5291 = 939,4643.$$

$$IC(\mu; 95\%) = [592,41 ; 939,46]$$

Representação gráfica

A figura mostra a curva t de Student com 24 graus de liberdade. A área central, de 95%, fica entre $-2,064$ e $+2,064$; sobram 2,5% em cada cauda, somando $\alpha = 5\%$. O valor $t_{\alpha/2} = 2,064$ é o ponto da tabela que separa essas áreas. A margem de erro do intervalo é esse valor multiplicado pelo erro padrão estimado, e foi isso que somamos e subtraímos de $\bar{x}$.



Interpretação

Com 95% de confiança, o gasto médio dos clientes da plataforma está entre R\$ 592,41 e R\$ 939,46. O nível de confiança se refere ao método: se repetíssemos o sorteio da amostra e a construção do intervalo muitas vezes, cerca de 95% dos intervalos obtidos conteriam a verdadeira média populacional μ .

3 Parte 3: Determinação do tamanho da amostra

Ideia

Na Parte 2, o tamanho da amostra era fixo e calculamos o intervalo. Agora fazemos o caminho inverso: fixamos o **erro máximo** que aceitamos cometer, ε , e o nível de confiança, e perguntamos qual o menor n que garante isso. Exige-se

$$P(|\bar{X} - \mu| \leq \varepsilon) \geq 1 - \alpha.$$

Fórmula

Como $\bar{X} \sim N(\mu, \sigma^2/n)$, padronizamos dividindo pelo erro padrão $\sigma/\sqrt{n}$:

$$P\left(-\frac{\sqrt{n}\varepsilon}{\sigma} \leq Z \leq \frac{\sqrt{n}\varepsilon}{\sigma}\right) = 1 - \alpha.$$

A área central $1 - \alpha$ fica entre $-z$ e $+z$, então o limite superior precisa ser o próprio z : $\sqrt{n}\varepsilon/\sigma = z$. Elevando ao quadrado e isolando n :

$$n = \frac{z^2 \sigma^2}{\varepsilon^2}$$

Como σ^2 é desconhecida, o enunciado manda usar a variância da amostra-piloto no lugar dela: $\sigma^2 \approx S^2$. Usa-se o z da normal, como na aula, porque o n é justamente o que ainda não conhecemos; como o resultado será bem maior que 25, a diferença para a distribuição t é desprezível.

Dados

$S^2 = 176\,711,76$ (Parte 1); $\varepsilon = \text{R\$ } 50,00$, na mesma unidade da variável (reais); confiança $1 - \alpha = 95\%$.


Valor crítico

Na Tabela III, que dá a área entre 0 e z , procuramos a área $(1 - \alpha)/2 = 0,95/2 = 0,47500$. Ela está na linha 1,9, coluna 6, logo

$$z = 1,96, \quad z^2 = 3,8416.$$

Representação gráfica

A curva é a normal padrão. A área central de 95% vai de $-1,96$ a $+1,96$. Na escala da média amostral, esse trecho corresponde a $\bar{X}$ ficar a no máximo ε de μ . Escolher n é ajustar o erro padrão $\sigma/\sqrt{n}$ para que 1,96 erros padrão caibam exatamente em $\varepsilon = 50$.



Cálculos

$$n = \frac{z^2 S^2}{\varepsilon^2} = \frac{3,8416 \cdot 176\,711,76}{50^2} = \frac{678\,855,91}{2\,500} = 271,5424.$$

O tamanho da amostra é sempre arredondado **para cima**: com 271 clientes o erro ficaria um pouco acima de 50, e arredondar para baixo não cumpriria a exigência. Logo,

$$n_{\min} = 272 \text{ clientes}$$

Verificação

A margem de erro obtida com cada tamanho é $z \cdot S/\sqrt{n}$, com $z \cdot S = 1,96 \cdot 420,3710 = 823,9271$:

$$\begin{aligned} n = 271 : \quad \frac{823,9271}{\sqrt{271}} &= \frac{823,9271}{16,4621} = 50,05 \quad (\text{maior que } 50), \\ n = 272 : \quad \frac{823,9271}{\sqrt{272}} &= \frac{823,9271}{16,4924} = 49,96 \quad (\text{menor que } 50). \end{aligned}$$

Conclusão

Para estimar o gasto médio dos clientes com 95% de confiança e erro máximo de R\$ 50,00, são necessários **no mínimo 272 clientes** na amostra. Esse valor depende da variância estimada na amostra-piloto: outra piloto daria outra estimativa de σ^2 e, portanto, outro n .

4 Parte 4: Distribuição da média amostral

O que foi feito

Foram extraídas 100 amostras aleatórias simples, todas do mesmo tamanho. O enunciado não diz qual é esse tamanho, apenas que deve ser igual para as 100 amostras; adotamos o tamanho mínimo encontrado na Parte 3, $n = 272$, para dar continuidade ao raciocínio (piloto, tamanho necessário, comportamento da média nesse tamanho). No final há um complemento com $n = 100$.

Cada amostra é uma AAS sem reposição de 272 clientes sorteados entre os 100 000, e as 100 amostras são sorteadas de forma independente, cada uma a partir da base completa (por isso um mesmo cliente pode aparecer em amostras diferentes). Para cada amostra j calculou-se a média de `Gasto_reais`, $\bar{x}_j$, com a semente 42.

As 100 médias amostrais (em R\$)

j	$\bar{x}_j$	j	$\bar{x}_j$	j	$\bar{x}_j$	j	$\bar{x}_j$
1	829,76	26	796,13	51	835,90	76	837,24
2	846,72	27	835,98	52	878,97	77	814,38
3	792,34	28	797,01	53	783,07	78	855,13
4	811,95	29	796,86	54	818,42	79	829,98
5	842,63	30	841,69	55	815,01	80	807,89
6	873,35	31	802,83	56	877,55	81	854,30
7	817,63	32	855,51	57	801,12	82	816,39
8	837,96	33	835,36	58	858,72	83	819,23
9	837,88	34	827,41	59	829,80	84	837,98
10	802,89	35	814,78	60	831,23	85	823,31
11	846,10	36	863,26	61	826,42	86	816,50
12	819,32	37	821,58	62	831,74	87	835,21
13	855,86	38	868,04	63	776,48	88	829,06
14	841,10	39	810,40	64	859,81	89	823,89
15	845,72	40	831,42	65	816,61	90	830,73
16	834,50	41	844,63	66	820,51	91	830,35
17	839,38	42	861,35	67	827,47	92	826,06
18	815,75	43	837,47	68	823,89	93	823,60
19	844,24	44	805,93	69	831,58	94	832,82
20	842,36	45	791,39	70	839,23	95	842,68
21	793,91	46	853,13	71	811,72	96	805,31
22	792,07	47	869,89	72	821,33	97	838,70
23	853,48	48	805,88	73	842,65	98	845,26
24	827,02	49	809,04	74	819,06	99	829,53
25	822,60	50	799,73	75	863,48	100	846,25

Média e desvio padrão das 100 médias

Tratando as 100 médias como um novo conjunto de dados:

$$\bar{\bar{x}} = \frac{1}{100} \sum_{j=1}^{100} \bar{x}_j = \frac{82\,936,77}{100} = 829,3677.$$

O desvio padrão usa o divisor $100 - 1 = 99$, como em toda variância amostral da disciplina:

$$s_{\bar{x}} = \sqrt{\frac{1}{99} \sum_{j=1}^{100} (\bar{x}_j - \bar{\bar{x}})^2} = \sqrt{\frac{44\,998,08}{99}} = 21,32.$$

Resultado da Parte 4: média das 100 médias = R\$ 829,37 e desvio padrão das 100 médias = R\$ 21,32.

Comparação com o que a teoria prevê (aula 03)


A distribuição amostral da média tem $E(\bar{X}) = \mu$ e desvio padrão igual ao erro padrão $\sigma/\sqrt{n}$. Com $\sigma = 387$ (valor informado na Parte 5) e $n = 272$:

$$\frac{\sigma}{\sqrt{n}} = \frac{387}{\sqrt{272}} = \frac{387}{16,4924} = 23,47.$$

- **Centro:** as médias se concentram em torno de R\$ 829,37. Como a base reúne todos os clientes, podemos calcular a média da população, apenas para comparação: R\$ 831,98. A média das 100 médias ficou muito próxima dela, o que ilustra $E(\bar{X}) = \mu$ (a média amostral não erra sistematicamente para cima nem para baixo).
- **Dispersão:** o desvio padrão observado, 21,32, tem a mesma ordem de grandeza do erro padrão teórico, 23,47. Não precisa ser idêntico: com apenas 100 médias, o próprio desvio padrão observado varia de um sorteio para outro.
- **Efeito de n :** as médias variam muito menos do que os gastos individuais, cujo desvio padrão é $\sigma = 387$. Dividir por $\sqrt{272} \approx 16,5$ é o que concentra as médias.

Representação gráfica

À esquerda, a distribuição dos gastos de toda a população: aproximadamente plana, sem formato de sino. À direita, o histograma das 100 médias, com a curva normal de mesma média e mesmo desvio padrão. Mesmo com a população longe de ser normal, as médias se distribuem em forma de sino, como diz o Teorema do Limite Central.



Complemento: o mesmo estudo com $n = 100$

Repetindo o procedimento com amostras de 100 clientes (mesma semente), obtemos média das 100 médias de R\$ 829,21 e desvio padrão de R\$ 42,65. O erro padrão teórico seria $387/\sqrt{100} = 38,70$. Com amostras menores as médias ficam mais dispersas (desvio padrão de 42,65 contra 21,32 com $n = 272$), em linha com a teoria: o erro padrão diminui quando n aumenta.

5 Parte 5: Teste de hipótese para a média

Em elaboração.